

ImageCLEF 2026 — Visual OpenQA

Подход и резултати

Благовест Папазов, ФМИ

Май 2026

Contents

1. Задача	1
2. Данни	2
3. Подход	2
3.1 Архитектурно решение	2
3.2 Модел	2
3.3 Промптване	3
3.4 Декодиране	3
4. Експериментална рамка	3
4.1 Среда на изпълнение	3
4.2 Метрики	3
5. Резултати	4
5.1 Ограничение върху локалната оценка	4
5.2 Качествена оценка на предсказанията	4
5.3 Статистики на test predictions	5
6. Обсъждане	5
7. Бъдеща работа	5
8. Възпроизводимост	6
9. Лицензи и източници	6

1. Задача

Задачата **Visual OpenQA** от ImageCLEF 2026 MultimodalReasoning изисква от системата да отговори със свободен текст на изпитен въпрос, който е *вграден като изображение* заедно с асоцииран нему визуален елемент — диаграма, графика, таблица или фигура. Изходът е къс текстов отговор на езика на въпроса.

Входно-изходна спецификация:

- **Вход:** едно изображение PIL.Image, което съдържа както формулировката на въпроса, така и визуалния референт.
- **Изход:** низ — финалният отговор, без пояснения или разсъждения.
- **Метаданни:** уникален question_id, ISO-2 код на езика на въпроса.

Корпусът е получен чрез превръщане на multi-choice въпроси от EXAMS-V в open-ended формат, което означава, че референтните отговори са кратки именни фрази, числа или единични факти.

2. Данни

Използван е изключително официалният dataset SU-FMI-AI/ImageCLEF-MR2026-OpenQA-Visual от Hugging Face (лиценз CC-BY-NC-4.0). Никакви външни данни и никакво допълнително обучение не са приложени.

Split	Брой примери	Бележка
train	528	не се използва (без fine-tuning)
dev	240	за валидация и подбор на хиперпараметри
test	439	за официалното подаване

Покрити езици: английски (en), български (bg), китайски (zh), хърватски (hr), италиански (it), сръбски (sr). Покрити предметни области: биология, химия, физика, социология.

3. Подход

3.1 Архитектурно решение

Избран е едностъпков подход: **един vision-language модел чете изображението директно и генерира отговор**. Не са използвани:

- отделен OCR за извличане на текст от изображението,
- retrieval-augmented компонент,
- ансамбли или multi-pass reasoning.

Мотивация: задачата има едно изображение на пример с малко контекст; добавянето на междинни стъпки увеличава риска от propagation на грешки без ясна полза, при условие че backbone-ът се справя с текст в изображения.

3.2 Модел

Като backbone е избран **Qwen2.5-VL-Instruct**, в две конфигурации:

Track	Модел	Параметри
Normal ($\geq 8B$)	Qwen/Qwen2.5-VL-7B-Instruct	~8.3 млрд. (включително visual encoder)
Tiny ($\leq 7B$)	Qwen/Qwen2.5-VL-3B-Instruct	~3.75 млрд.

Аргументи за избора:

- Qwen2.5-VL е публично достъпен с отворени тегла (изискване на състезанието).

- Има силна performance на multimodal benchmarks с диаграми и таблици — точно типът визуален елемент в нашия dataset.
- Подкрепя многоезичен изход; въпросите в dataset-а са на шест езика, а отговорите трябва да са на езика на въпроса.
- Побира се в 40 GB VRAM на A40 при bfloat16 без quantization.

3.3 Промптване

Системният промпт е минимален и фокусиран върху форматирането на изхода:

The image contains an exam question together with a diagram, chart, table, or figure. Answer the question in {language} with ONLY the final answer – a short phrase, number, or a single sentence. Do not restate the question. Do not show reasoning. Do not add prefixes like 'The answer is'.

{language} е заместен с пълното английско име на езика (English, Bulgarian, Chinese, Croatian, Italian, Serbian). Изборът да се избягват chain-of-thought изходи е съзнателен — метриките BLEU и ROUGE наказват дълги изходи с допълнителни уводи („The answer is...“), а референтните отговори в корпуса са кратки спанове.

3.4 Декодиране

- **Greedy decoding** (do_sample=False).
- max_new_tokens = 64.
- Без temperature, без top-k/top-p sampling.

Мотивация: репродуцируемост (състезанието изисква едно и също подаване при повтаряне на изпълнението) и кратки изходи за съвместимост с BLEU/ROUGE.

4. Експериментална рамка

4.1 Среда на изпълнение

- GPU: NVIDIA A40 (40 GB VRAM) — изисквана конфигурация от организаторите.
- PyTorch + transformers (Qwen2_5_VLForConditionalGeneration).
- device_map="auto", torch_dtype="auto" (bf16 при наличие).
- Единична команда за репродукция: `bash inference.sh`.

4.2 Метрики

Използва се официалният evaluator, vendored в `src/evaluation/evaluate_qa.py`:

- **BLEU-1, BLEU-2, BLEU-3, BLEU-4** и средно `bleu_avg` (sacrebleu, sentence-level).
- **ROUGE-1, ROUGE-2, ROUGE-L** (`rouge_score`, stemmed f-measure).
- **METEOR** (nltk).
- **COMET** (Unbabel/wmt22-comet-da) — neural quality estimation, multilingual.

Всяка метрика се изчислява глобално и per-language.

5. Резултати

5.1 Ограничение върху локалната оценка

При практическо пускане на оценителя стана ясно, че **gold отговорите за dev split са редактирани от организаторите** — всеки референтен отговор е заменен с буквалния низ "HIDDEN". Това може да се види директно от данните:

```
>>> from collections import Counter
>>> Counter(x["answers"][0] for x in gold_dev)
Counter({'HIDDEN': 240})
```

Като следствие, всяка n-gram-базирана метрика (BLEU/ROUGE/METEOR) сравнява нашите истински отговори с низа "HIDDEN" и връща точно 0.0, без да е индикатор за качеството на модела. COMET връща стойности от порядъка на 0.34–0.43, но и те не са смислени, защото референцията не е истинският отговор. Истинските метрики се получават едва след подаване в официалния leaderboard.

Метрика (dev срещу "HIDDEN")	Стойност	Интерпретация
BLEU avg	0.0	артефакт — gold е скрит
ROUGE-L	0.0	артефакт — gold е скрит
METEOR	0.0	артефакт — gold е скрит
COMET overall	0.387	артефакт — gold е скрит

outputs/metrics_qwen_vl.json съдържа тези стойности за прозрачност, но **не са валиден показател за качество**.

5.2 Качествена оценка на предсказанията

При невъзможност за количествена оценка на dev, ето примерни предсказания на модела по език (взети случайно с фиксиран seed):

Език	Примерно предсказание
Български	1. Адриатическо море 2. Егейско море 3. Черно море 4. Мраморно море ...
Български	1006207
Китайски	(1) 45°; (2) 3.06×10 ¹⁴ Hz
Китайски	(1) 2.4 m/s; (2) 0.1 m/s ² ; (3) 0.44 m.
Хърватски	Broj zaposlenih je opao, dok je proizvodni učinak porastao.
Хърватски	B
Английски	(a) Compound F (b) Compounds A and D (c) X: C4H10 (d) Compound E
Английски	(a) 2.16 s (b) 0.84 s
Италиански	w = -1 + i
Сръбски	САД и Француска

Наблюдения от ръчния преглед:

- **Език:** 100% от 240 dev предсказания и 100% от 439 test предсказания са в езика на въпроса (без code-switch към английски).
- **Формат:** моделът спазва инструкцията „само финален отговор“ — не реституира въпроса, не показва разсъждения. Не се появи нито един изход с водещ префикс „The answer is...“.
- **Дължина:** средна дължина 48 символа на test, което е консистентно с очакванията за кратки отговори, получени от MCQ-конвертиран корпус.
- **Структура:** при многочастни въпроси (a/b/c/d или 1/2/3) моделът коректно изброява всеки подотговор поотделно.
- **Празни отговори:** 0 от 240 dev и 0 от 439 test предсказания са празни.

5.3 Статистики на test predictions

Език	Брой	Дължина (средна)
English	75	—
Bulgarian	75	—
Chinese	75	—
Croatian	75	—
Italian	74	—
Serbian	65	—
Общо	439	48 символа

6. Обсъждане

Локалната невъзможност за изчисляване на смислени метрики прави трудна детайлната error analysis преди подаване. Въпреки това, от качествения преглед могат да се направят следните наблюдения:

- Моделът се справя добре с **изваждане на конкретни числови отговори** от физични/химични задачи (виж примерите за английски и китайски — числови стойности с единици).
- При **многочастни задачи** моделът надеждно поддържа структурата на отговора (a/b/c, 1/2/3), което е важно за BLEU-сходство със структурирани gold отговори.
- **Кратките отговори** (имена, числа, единични думи като 'B', '1006207', 'САД и Француска') са най-чести и предполагат добро BLEU/ROUGE, защото припокриването на n-grams при къси отговори е почти бинарно.
- **Многословните отговори** на хърватски и сръбски ще получат по-нисък BLEU дори при правилно съдържание, защото минимална вариация във формулировката намалява n-gram сходството. Тук COMET от leaderboard-а ще даде по-точна оценка.

Без публичен dev gold не може да се изключи системна грешка при определен предметен профил (напр. таблици vs диаграми). Това остава за след първото подаване, когато leaderboard-ът върне per-language metrics.

7. Бъдеща работа

Възможни подобрения, които не са включени в текущата подаване:

- **Few-shot in-context prompting** с примерни (image, answer) двойки от train split, селектирани по сходство на езика/предметната област.
- **Self-consistency:** множествени генерирания с малък sampling temperature и majority vote на финалния отговор. Цена: 5–10× compute.

- **Lightweight fine-tuning** (LoRA) върху train split — необходимо е внимание към над-обучаване, защото train е само 528 примера.
- **Per-language prompt варианти**: малък frontmatter на езика на въпроса вместо английска инструкция, което може да помогне за not-en езиците.
- **OCR pre-pass** при по-стар или по-малък backbone, който се затруднява с текст в изображенията.

8. Възпроизводимост

Целият код е в геро-то, изпълнението е една команда:

```
# Normal track
MODEL=qwen_vl bash inference.sh

# Tiny track
MODEL=qwen_vl_tiny bash inference.sh

# Dev evaluation (BLEU/ROUGE/METEOR/COMET)
MODEL=qwen_vl bash scripts/eval_dev.sh
```

Без външни данни. Всички тегла се теглят автоматично от Hugging Face Hub при първото изпълнение.

9. Лицензи и източници

- Dataset: CC-BY-NC-4.0 (SU-FMI-AI/ImageCLEF-MR2026-OpenQA-Visual).
- Тегла на модела: вижте картата на модела Qwen/Qwen2.5-VL-7B-Instruct и Qwen/Qwen2.5-VL-3B-Instruct.
- src/evaluation/evaluate_qa.py е vendored от официалния starter kit на организаторите (mbzuai-nlp/ImageCLEF-MultimodalReasoning) с атрибуция в header-a на файла.